



UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA RAČUNARSTVO I INFORMATIKU

Primjena metoda dubokog učenja za klasifikaciju CT medicinskih slika

ZAVRŠNI RAD
- PRVI CIKLUS STUDIJA -

Student:
Amila Babić

Mentor:
red. prof. dr. Emir Buza

Sarajevo, 2026. godine

Sažetak

Rak pluća jedan je od vodećih uzroka smrtnosti od raka u svijetu, te je veoma važna rana detekcija. Ručna analiza CT snimaka zahtijeva vrijeme, znanje stručnjaka, te je podložna greškama, što ukazuje na potrebu za primjenom metoda dubokog učenja u analizi medicinskih slika. U ovom radu implementirana su dva modela dubokog učenja: 3D CNN i ResNet, korištenjem NoduleMNIST3D skupa podataka u TensorFlow/Keras okruženju. NoduleMNIST3D je standardizirani skup podataka iz MedMNIST kolekcije, baziran na LIDC-IDRI skupu podataka, koji sadrži 3D CT snimke plućnih nodula dimenzija $28 \times 28 \times 28$. Skup podataka je podijeljen na skup podataka za testiranje (1158 uzoraka), skup podataka za validaciju (165 uzoraka) i skup podataka za testiranje (310 uzoraka), te je namijenjen binarnoj klasifikaciji plućnih nodula na benigne i maligne. 3D CNN model sastoji se od dva konvolucijska bloka i klasifikacijskog dijela, dok ResNet model koristi rezidualne veze i GlobalAveragePooling3D sloj. Oba modela trenirana su korištenjem Adam optimizatora s početnom stopom učenja 0.0001, Binary Cross-Entropy funkcijom gubitka i Early Stopping callbackom. CNN model postigao je tačnost od 83.55% i AUC od 88.31%, dok je ResNet model postigao nešto lošije rezultate, tačnost od 83.23% i AUC od 86.12%. Poređenjem s benchmark rezultatima Yang i saradnika na istom skupu podataka, implementirani CNN model postiže viši AUC od ResNet-18 (3D) modela (88.31% naspram 86.3%), što ukazuje da su dobiveni rezultati kompetitivni s postojećim metodama iz literature. Na osnovu analize rezultata, CNN model se pokazao povoljnijim izborom, posebno gledajući Recall i AUC metrike, koje su i najvažnije u kontekstu detekcije malignih plućnih nodula.

Ključne riječi: duboko učenje, klasifikacija medicinskih slika, plućni noduli, konvolucijska neuronska mreža, ResNet, NoduleMNIST3D

Abstract

Lung cancer is one of the leading causes of cancer-related mortality worldwide, making early detection particularly important. Manual analysis of CT scans requires time and expert knowledge, and is prone to errors, indicating the need for deep learning methods in medical image analysis. In this work, two deep learning models were implemented: 3D CNN and ResNet, using the NoduleMNIST3D dataset in the TensorFlow/Keras framework. NoduleMNIST3D is a standardized dataset from the MedMNIST collection, based on the LIDC-IDRI dataset, containing 3D CT scans of pulmonary nodules of dimensions $28 \times 28 \times 28$. The dataset is divided into training (1158 samples), validation (165 samples) and test set (310 samples), designed for binary classification of pulmonary nodules into benign and malignant. The 3D CNN model consists of two convolutional blocks and a classification head, while the ResNet model utilizes residual connections and a GlobalAveragePooling3D layer. Both models were trained using the Adam optimizer with an initial learning rate of 0.0001, Binary Cross-Entropy loss function and Early Stopping callback. The CNN model achieved an accuracy of 83.55% and AUC of 88.31%, while the ResNet model achieved slightly lower results, with an accuracy of 83.23% and AUC of 86.12%. Compared to the benchmark results of Yang et al. on the same dataset, the implemented CNN model achieves higher AUC than the ResNet-18 (3D) model (88.31% vs 86.3%), indicating that the obtained results are competitive with existing methods in the literature. Based on the analysis of all metrics, the CNN model proved to be a more favorable choice, particularly regarding Recall and AUC metrics, which are most important in the context of detecting malignant pulmonary nodules.

Keywords: deep learning, medical image classification, pulmonary nodules, convolutional neural network, ResNet, NoduleMNIST3D

Elektrotehnički fakultet, Univerzitet u Sarajevu
Odsjek za računarstvo i informatiku
red. prof. dr. Emir Buza
Sarajevo, 24.08.2026.

Postavka zadatka završnog rada I ciklusa: **Predložak za izradu završnog rada I ciklusa - uz korištenje Latexa kao alata**

U okviru rada je potrebno razviti $\text{\LaTeX}$ predložak za izradu završnog rada drugog ciklusa studija. U radu je potrebno:

- objasniti opći postupak za izradu i pisanje završnih radova drugog ciklusa studija, poštivajući odgovarajuće Pravilnike,
- dati kratko uputstvo za korištenje .tex dokumenata, pisanje slika, tabela i relacija, generisanje sadržaja, popisa slika i tabela i sl.
- dati kratko uputo za generiranje odgovarajućih .pdf dokumenata iz odgovarajućih .tex fajlova,

Preporučuje se korištenje TexLive $\text{\LaTeX}$ podrške, verzije 2013 ili novije.

Napomena: U dijelu "Postavka" se stavlja postavka rada koju je specificirao mentor prilikom davanja teme. Naročito obratiti pažnju na naslov rada koji mora biti konzistentan tokom cijelog dokumenta, i usaglašen sa temom upisanom u informacijski sistem (npr. Zamger). Na ovoj stranici se potpisuje mentor prije nego se radovi odnesu u studentsku službu.

Polazna literatura:

- [1] Sonka, M., Hlavac, V., Boyle, R., "Image Processing, Analysis, and Machine Vision", Thomson, 2008.
- [2] Lee, E.A., Varaiya, P., "Structure and Interpretation of Signals and Systems", Electrical Engineering & Computer Science University of California, Berkeley, 2000

red. prof. dr. Emir Buza

Izjava o autentičnosti radova

Završni rad I ciklusa studija

Ime i prezime: Amila Babić

Naslov rada: Primjena metoda dubokog učenja za klasifikaciju CT medicinskih slika

Vrsta rada: Završni rad prvog ciklusa studija

Broj stranica:

Potvrđujem:

- da sam pročitao dokumente koji se odnose na plagijarizam, kako je to definirano Statutom Univerziteta u Sarajevu, Etičkim kodeksom Univerziteta u Sarajevu i pravilima studiranja koja se odnose na I i II ciklus studija, integrirani studijski program I i II ciklusa i III ciklus studija na Univerzitetu u Sarajevu, kao i uputama o plagijarizmu navedenim na web stranici Univerziteta u Sarajevu;
- da sam svjestan univerzitetskih disciplinskih pravila koja se tiču plagijarizma;
- da je rad koji predajem potpuno moj, samostalni rad, osim u dijelovima gdje je to naznačeno;
- da rad nije predat, u cjelini ili djelimično, za stjecanje zvanja na Univerzitetu u Sarajevu ili nekoj drugoj visokoškolskoj ustanovi;
- da sam jasno naznačio prisustvo citiranog ili parafraziranog materijala i da sam se referirao na sve izvore;
- da sam dosljedno naveo korištene i citirane izvore ili bibliografiju po nekom od preporučenih stilova citiranja, sa navođenjem potpune reference koja obuhvata potpuni bibliografski opis korištenog i citiranog izvora;
- da sam odgovarajuće naznačio svaku pomoć koju sam dobio pored pomoći mentora i akademskih tutora/ica.

Sarajevo, datum 24.08.2026.

Potpis:

Amila Babić

Sadržaj

Popis slika	vii
-------------	-----

Popis tabela	viii
--------------	------

1	Uvod	1
1.1	Obrazloženje teme	1
1.2	Pregled stanja u oblasti istraživanja	1
1.2.1	Razvoj automatizovane analize medicinskih slika	1
1.2.2	Primjena dubokog učenja u analizi CT slika	2
1.2.3	Klasifikacija plućnih nodula na CT slikama	2
1.2.4	CNN modeli za klasifikaciju CT slika	2
1.2.5	RNN i hibridni modeli u klasifikaciji CT slika	3
1.3	Motivacija istraživanja	3
1.4	Osnovni ciljevi i plan istraživanja	3
1.5	Metodologija istraživanja	3
1.6	Očekivani rezultati	3
1.7	Struktura završnog rada	4
2	Teorijske osnove	5
2.1	Osnove neuronskih mreža	5
2.1.1	Aktivacijske funkcije	6
2.1.2	Backpropagation	6
2.2	Konvolucijske neuronske mreže	6
2.2.1	Pooling sloj	7
2.2.2	Dropout	8
2.2.3	Batch Normalization	8
2.2.4	Global Average Pooling	9
2.2.5	Potpuno povezani slojevi	9
2.2.6	3D konvolucijske neuronske mreže	9
2.2.7	ResNet arhitektura	9
2.2.8	Adam optimizator	10
2.2.9	Loss funkcija	10
3	Implementacija	12
3.1	NoduleMNIST3D skup podataka	12
3.2	Arhitektura modela	13
3.2.1	3D CNN	13
3.2.2	ResNet3D	16
3.3	Trening i evaluacija	18

4	Rezultati i diskusija	22
4.1	Rezultati	22
4.2	Poređenje s literaturom	26
4.3	Diskusija	26
	Zaključak	29
	Literatura	31

Popis slika

2.1	Arhitektura neuronske mreže	5
2.2	Primjer max pooling operacije sa filterom veličine 2×2	7
3.1	Primjeri plućnih nodula iz NoduleMNIST3D skupa podataka – benigni (gore) i maligni (dole)	13
3.2	Blokovski dijagram arhitekture 3D CNN modela	14
3.3	Implementacija 3D CNN arhitekture u TensorFlow/Keras	15
3.4	Pregled slojeva i parametara 3D CNN modela	15
3.5	Blokovski dijagram arhitekture ResNet modela	16
3.6	Implementacija ResNet arhitekture u TensorFlow/Keras	17
3.7	Pregled slojeva i parametara ResNet modela	18
3.8	Kod treniranja 3D CNN modela	19
3.9	Kod treniranja ResNet modela	19
3.10	Grafovi tačnosti i gubitka tokom treniranja 3D CNN i ResNet modela	21
4.1	Confusion Matrix za 3D CNN i ResNet model	23
4.2	ROC krivulja za 3D CNN i ResNet model	24
4.3	Maligni noduli koje 3D CNN model ispravno klasificira, a ResNet model propušta (FN)	24
4.4	Maligni noduli koje oba modela ispravno klasificiraju (TP)	25
4.5	Maligni noduli koje oba modela propuštaju (FN)	25
4.6	Benigni noduli koje CNN pogrešno klasificira kao maligne (FP), a ResNet ispravno (TN)	25

Popis tabela

4.1	Poređenje rezultata 3D CNN i ResNet modela	22
4.2	Poređenje rezultata s literaturom	26

Poglavlje 1

Uvod

1.1 Obrazloženje teme

CT – kompjuterizovana tomografija (engl. *computed tomography*) predstavlja dijagnostičku metodu koja je unijela velike promjene u medicinsku dijagnostiku, pružajući uvid u unutrašnje strukture ljudskog tijela [1]. CT snimci su važni za otkrivanje i dijagnostiku brojnih promjena i oboljenja unutar tijela, kao što su tumori, krvarenja i upale [2].

Zbog toga je ključno ispravno i detaljno tumačenje snimaka, što može biti veoma izazovno i vremenski zahtjevno, te zahtijevati veliko znanje i iskustvo medicinskih stručnjaka [1]. Međutim, ograničena dostupnost stručnjaka, kao i dugotrajnost i mogućnost greške pri analizi CT snimaka, mogu ograničiti efikasnost dijagnostičkog procesa [3]. Sa razvojem kvaliteta snimaka i njihovom sve većom zastupljenošću u medicini razvila se potreba za automatizovanim i efikasnijim metodama za analizu i interpretaciju ovih snimaka. [1].

Automatizovana klasifikacija CT slika može olakšati i ubrzati proces interpretacije snimaka te unaprijediti dijagnostičke mogućnosti. Ovakav pristup ima potencijal doprinijeti većoj efikasnosti i tačnosti dijagnostičkog procesa, kao i smanjenju opterećenja radiologa automatizacijom početnih koraka analize [1]. Shodno tome, razvoj i usavršavanje modela dubokog učenja za klasifikaciju CT slika predstavlja značajno područje istraživanja [1].

Mikroskopska istraživanja, poput CT-a, ultrazvuka i drugih, koriste se za ispitivanje tkiva raka [4]. Rak pluća bio je najčešće dijagnosticiran rak u 2022. godini i vodeći uzrok smrti od raka, sa procijenjenih 1,8 miliona smrtnih slučajeva (18,7%) [5]. CT analiza predstavlja važnu metodu za prikaz i analizu plućnih nodula, jer omogućava trodimenzionalni prikaz grudnog koša i detaljniji prikaz nodula [6]. Pri analizi plućnih nodula prikazanih na CT snimcima razlikovanje benignih i malignih plućnih nodula predstavlja važan klasifikacijski zadatak koji se može istraživati primjenom metoda dubokog učenja [6].

U ovom radu analizira se primjena metoda dubokog učenja za klasifikaciju plućnih nodula prikazanih na CT snimcima u benigne i maligne kategorije.

1.2 Pregled stanja u oblasti istraživanja

1.2.1 Razvoj automatizovane analize medicinskih slika

Čim je bilo moguće skenirati i učitati medicinske slike u računar, istraživači su razvili sisteme za njihovu automatizovanu analizu. Analiza medicinskih slika u početku je podrazumijevala sekvencijalnu primjenu niskonivojske obrade piksela i matematičkog modeliranja kako bi se konstruisali složeni sistemi zasnovani na pravilima koji su rješavali određene zadatke [7].

Već krajem 1990-ih godina, nadzirano učenje, u kojem model uči na osnovu prethodno označenih podataka koji sadrže ulazne podatke i tačan ishod, postalo je značajno zastupljeno u analizi medicinskih slika. Ovaj pristup mašinskog učenja i dalje je veoma popularan i čini osnovu mnogih sistema za analizu medicinskih slika [7].

Duboko učenje, podskupina mašinskog učenja, postoji već dugo, ali je steklo značajnu popularnost tek početkom 2010-ih, kada su odgovarajući podaci i hardver bili dostupni. U tom periodu ostvarilo je velike rezultate na perceptivnim problemima kao što su vid i sluh, dotada nedostižnim za mašine [8].

1.2.2 Primjena dubokog učenja u analizi CT slika

Duboko učenje (engl. *deep learning*, DL) pokazuje veliki potencijal u analizi medicinskih slika jer omogućava modelima da automatski prepoznaju složene obrasce na snimcima, što može doprinijeti preciznijem otkrivanju i klasifikaciji bolesti [9].

Modeli dubokog učenja automatski uče i izdvajaju karakteristike iz velikih skupova podataka, zbog čega su pogodni za klasifikaciju slika. DL modeli se mogu trenirati za prepoznavanje specifičnih anatomskih struktura, otkrivanje abnormalnosti i klasifikaciju medicinskih slika sa visokom tačnošću i efikasnošću [1].

Primjena naprednih tehnika dubokog učenja u analizi CT slika pokazala je obećavajuće rezultate u poboljšanju brzine i tačnosti otkrivanja i dijagnosticiranja bolesti. Ovi pristupi, zasnovani na umjetnoj inteligenciji, ne samo da mogu pomoći u bržem dijagnosticiranju, već imaju potencijal da smanje opterećenje zdravstvenih sistema automatizacijom pojedinih koraka analize [1].

1.2.3 Klasifikacija plućnih nodula na CT slikama

Proces računarski potpomognute dijagnostike (CAD) raka pluća može biti podijeljen na sistem za detekciju (CADE) i dijagnostički sistem (CADx). CADe sistem detektuje moguće nodule u CT snimku. Cilj CADx sistema je klasifikacija prethodno izdvojenih plućnih nodula na benigne i maligne. Pri klasifikaciji plućnih nodula u benigne i maligne kategorije CADx se može koristiti karakteristikama kao što su tekstura, oblik i izgled [6].

Song i saradnici ispitivali su različite modele dubokog učenja za klasifikaciju plućnih nodula na CT slikama u benigne i maligne kategorije. Upoređeni su CNN, DNN i SAE modeli, te je među njima CNN imao najbolje rezultate: tačnost= 84,15%, osjetljivost= 83,96%, specifičnost= 84,32% [6].

1.2.4 CNN modeli za klasifikaciju CT slika

Među najznačajnijim modelima za analizu slika su konvolucijske neuronske mreže (engl. *convolutional neural networks*, CNN) [7].

CNN modeli su namijenjeni za obradu vizuelnih podataka i sastoje se od više slojeva konvolucijskih i *pooling* operacija, nakon kojih slijede potpuno povezani slojevi za klasifikaciju [3]. Ove mreže uspješno su primijenjene na niz zadataka u analizi medicinskih slika, uključujući otkrivanje tumora, segmentaciju organa i klasifikaciju bolesti. Korištenjem hijerarhijskih karakteristika koje CNN modeli uče iz podataka, istraživači su postigli značajne rezultate u analizi CT slika [1, 3].

1.2.5 RNN i hibridni modeli u klasifikaciji CT slika

Osim CNN modela, rekurentne neuronske mreže (engl. *recurrent neural networks*, RNN) istraživane su za klasifikaciju CT slika, posebno u zadacima koji uključuju sekvencijalne podatke ili analizu vremenskih promjena. RNN modeli pogodni su za praćenje promjena u karakteristikama slike tokom vremena i analizu ulaznih sekvenci promjenjive dužine [1].

Kombinovanjem CNN i RNN modela razvijene su hibridne arhitekture koje omogućavaju analizu složenih obrazaca u CT slikama. U takvim arhitekturama CNN dio modela koristi se za izdvajanje prostornih karakteristika iz snimaka, dok se RNN dio koristi za analizu sekvencijalnih ili vremenskih odnosa među podacima [1].

1.3 Motivacija istraživanja

Duboko učenje ima odlične rezultate u problemima koji uključuju vještine koje ljudima djeluju prirodno i intuitivno, ali iziskuju mnogo vremena, koncentracije, te nažalost učestale su i pogreške tokom rada [8]. Upravo ta ograničenja su razlog mog istraživanja primjene DL algoritama u medicinskoj dijagnostici. Uz mamu doktoricu, medicina je postala moja oblast interesovanja, koja je vremenom rasla, te me motiviše da tehnologiju primijenim u medicinske svrhe. U okviru predmeta Vještačka inteligencija, gdje sam učila o neuronskim mrežama i CNN-u, uz praktičan rad u *Pythonu* i *TensorFlowu*, usmjerila sam se na primjenu metoda dubokog učenja za klasifikaciju CT medicinskih slika.

1.4 Osnovni ciljevi i plan istraživanja

Budući da je rak pluća ozbiljan problem, te je rana dijagnostika neophodna za bolje ishode liječenja, potrebno je unaprijediti postojeće metode dijagnostike [5, 9]. Međutim, ručna analiza CT snimaka je vremenski zahtjevna, zahtijeva specijalizovano znanje, te je podložna greškama [9]. Cilj ovog rada je klasifikacija plućnih nodula na CT snimcima na benigne i maligne primjenom CNN modela. Očekuje se da će ovo istraživanje pokazati da metoda dubokog učenja može unaprijediti trenutnu analizu CT snimaka i time olakšati i ubrzati rad radiologa.

1.5 Metodologija istraživanja

Kao što je navedeno u poglavlju 1.2, za klasifikaciju CT slika koriste se CNN, RNN i hibridni modeli. Za potrebe ovog rada odabran je CNN zbog česte primjene u klasifikaciji plućnih nodula, te pokazivanja visoke tačnosti u klasifikaciji CT slika [3, 6]. U radu je korišten NoduleMNIST3D skup podataka [10], baziran na LIDC-IDRI skupu podataka i namijenjen binarnoj klasifikaciji plućnih nodula na benigne i maligne. Skup podataka sadrži 1158 uzoraka za trening, 165 za validaciju i 310 za testiranje, a svaka slika je dimenzija $28 \times 28 \times 28$. Izvršit će se programska implementacija i analiza rezultata klasifikacije primjenom 3D CNN i ResNet3D modela, te poređenje između ova dva modela.

1.6 Očekivani rezultati

Očekuje se da će implementirani CNN model postići visoku tačnost u klasifikaciji plućnih nodula na benigne i maligne. Poređenjem 3D CNN i ResNet3D modela očekuje se prepoznavanje

efikasnijeg pristupa za dati klasifikacijski zadatak, te postizanje boljih performansi modela. Rezultati istraživanja mogu doprinijeti razvoju automatizovanih metoda za analizu CT slika [1].

1.7 Struktura završnog rada

Rad je organiziran u četiri poglavlja. Prvo poglavlje (1) daje uvod u problematiku, motivaciju istraživanja, pregled stanja u oblasti, ciljeve rada te očekivane rezultate.

Drugo poglavlje (2) opisuje teorijske osnove korištene u implementaciji modela dubokog učenja, uključujući osnove neuronskih mreža, konvolucijske neuronske mreže, 3D CNN i ResNet arhitekturu.

Treće poglavlje (3) opisuje implementaciju dva modela, CNN i ResNet, njihovu arhitekturu, te proces treniranja i evaluacije. Četvrto poglavlje (4) prikazuje rezultate evaluacije oba modela, njihovo međusobno poređenje, poređenje s literaturom te diskusiju rezultata.

Na kraju rada dat je Zaključak s ostvarenim ciljevima rada i smjernicama za budući rad.

* * *


U ovom poglavlju opisana je motivacija istraživanja, pregled stanja u oblasti, ciljevi rada, kao i očekivani rezultati, što ukazuje na potrebu za automatiziranim metodama klasifikacije plućnih nodula korištenjem dubokog učenja. Teorijske osnove potrebne za razumijevanje implementiranih metoda opisane su u narednom poglavlju.

Poglavlje 2

Teorijske osnove

2.1 Osnove neuronskih mreža

Neuronska mreža, inspirirana ljudskim nervnim sistemom, trenira model koji, nakon procesa učenja, ima sposobnost prepoznavanja obrazaca i donošenja odluka o podacima koje prvi put vidi. Neuroni su raspoređeni u više slojeva, pri čemu svaki sloj transformiše podatke. Postoje tri osnovne vrste slojeva: ulazni, skriveni i izlazni. Ulazni sloj prima ulazne podatke, te ih prosljeđuje dalje. Jedan skriveni sloj ili više njih obrađuje podatke. Izlazni sloj generiše krajnji rezultat, sadrži onoliko neurona koliko postoji klasa (u problemu klasifikacije), a kod binarne klasifikacije sadrži samo jedan neuron koji određuje kojoj klasi uzorak pripada [8].



Slika 2.1: Arhitektura neuronske mreže

Svaki neuron u mreži računa linearnu kombinaciju ulaza i težina, dodavajući i bias, te se nakon toga primjenjuje aktivacijska funkcija [7]:

$$a = \sigma(\mathbf{w}^T \mathbf{x} + b) \quad (2.1)$$

gdje su:

- a – izlaz neurona,
- σ – aktivacijska funkcija,
- $\mathbf{w}$ – vektor težina,

- $\mathbf{x}$ – ulazni vektor,
- b – bias.

2.1.1 Aktivacijske funkcije

Aktivacijske funkcije unose nelinearnost u neuronsku mrežu, primjenjujući nelinearnu transformaciju, čime omogućavaju učenje složenih obrazaca. Za potrebe ovog rada u skrivenim slojevima koristit će se ReLU, a u izlaznom sloju Sigmoid aktivacijska funkcija.

ReLU funkcija vraća nulu ukoliko je ulazna vrijednost negativna, a ukoliko je pozitivna samo prosljeđuje tu vrijednost:

$$f(x) = \max(0, x) \quad (2.2)$$

Zbog toga je ReLU jednostavna za računanje, rješava problem nestajućeg gradijenta i koristi se u CNN modelima u skrivenim slojevima [8].

Sigmoid aktivacijska funkcija se koristi za binarnu klasifikaciju u izlaznom sloju, jer transformiše izlaz na interval od 0 do 1 [8]:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.3)$$

2.1.2 Backpropagation

Backpropagation je algoritam koji trenira neuronske mreže smanjenjem greške. Greška se mjeri funkcijom gubitka (engl. *loss function*), koja izračunava razliku između stvarne vrijednosti i predikcije. Ta vrijednost se koristi kao signal za prilagođavanje težina neurona. Proces treniranja se ponavlja kroz iteracije, a *backpropagation* računa koliko svaka težina doprinosi grešci, krećući se unazad kroz mrežu [8].

2.2 Konvolucijske neuronske mreže

CNN modeli se sastoje od više slojeva, uključujući konvolucijske slojeve, pooling slojeve i potpuno povezane slojeve, koji imaju različite funkcije te moraju zajedno raditi kako bi prepoznali obrasce na slikama i donijeli zaključak [1]. Svaki od navedenih slojeva detaljnije je opisan u nastavku.

Dvije su ključne razlike između neuronskih mreža i konvolucijskih neuronskih mreža. Obične neuronske mreže moraju učiti pojedinačne detektore za svaku poziciju kako bi prepoznale isti objekt na različitim pozicijama. Kod konvolucijskih neuronskih mreža težine se dijele na način da mreža realizuje operacije konvolucije na slikama, nakon čega model ne mora učiti odvojene detektore za isti objekt, što mrežu čini ekvivarijantnom u odnosu na translacije ulaza. Također drastično smanjuje količinu parametara koje je potrebno naučiti, iz razloga što broj težina više ne ovisi o veličini ulazne slike. Operacija konvolucije matematički se opisuje sljedećom formulom [7]:

$$X_k^l = \sigma(W_k^{l-1} * X^{l-1} + b_k^{l-1}) \quad (2.4)$$

gdje su:

- X_k^l – izlazna mapa karakteristika (engl. *feature map*) k -tog kernela u sloju l ,
- W_k^{l-1} – k -ti kernel (filter) u prethodnom sloju,

- X^{l-1} – ulazna mapa karakteristika iz prethodnog sloja,
- b_k^{l-1} – bias k -tog kernela,
- σ – aktivacijska funkcija,
- $k = 1, 2, \dots, K$ – indeks kernela, pri čemu postoji ukupno K kernela.

Mapa karakteristika nastaje kao izlaz iz konvolucijskog sloja koji predstavlja gdje se specifične karakteristike nalaze na ulaznoj slici. Tokom prolaska kroz mrežu svaki kernel traži drugačiju karakteristiku, te svaka mapa karakteristika odgovara određenom filteru [8].

Druga ključna razlika je *pooling* slojevi koje sadrži konvolucijska neuronska mreža, gdje se sažimaju vrijednosti susjednih piksela u jednu vrijednost. Ovime mreža sadrži manje parametara i postiže translacionu invarijantnost [7].


2.2.1 Pooling sloj

Pooling sloj smanjuje dimenzije mapa karakteristika zadržavajući najvažnije informacije. Smanjenje dimenzionalnosti olakšava treniranje modela, s obzirom da nakon pooling sloja model ima manje parametara, ali i dalje sadržavajući najznačajnije karakteristike iz ulaznih podataka. Međutim, ukoliko su veličina filtera i broj pooling slojeva preveliki, može doći do gubitka važnih informacija. Najčešće se koristi max pooling, koji uzima maksimalnu vrijednost iz svake regije mape, te se matematički može prikazati formulom [8]:

$$y = \max_{(i,j) \in R} x_{i,j} \quad (2.5)$$

gdje su:

- y – izlazna vrijednost (jedan piksel u smanjenoj mapi),
- R – regija (prozor) ulaznih piksela,
- $x_{i,j}$ – vrijednost piksela na poziciji (i, j) unutar regije R .



Slika 2.2: Primjer max pooling operacije sa filterom veličine 2×2

U radu će se implementirati max pooling sloj kako bi se smanjila dimenzija i time došlo do bržeg izračunavanja i manjeg broja parametara, te kako bi se zadržale važne karakteristike.

2.2.2 Dropout

Jedan od značajnih problema kod neuronskih mreža je *overfitting* - pojava kada mreža ima dobre rezultate na treningu, a loše na testu. Kako bi se smanjio *overfitting*, odnosno kako mreža ne bi napamet zapamtila skup podataka za treniranje, uvodi se dropout sloj. Dropout nasumično isključuje neurone tokom treniranja. U svakom trening primjeru nasumično se biraju neuroni koji se isključuju. Dropout se može matematički prikazati sljedećom formulom [8]:

$$y_i = r_i \cdot x_i, \quad r_i \sim \text{Bernoulli}(1 - p) \quad (2.6)$$

gdje su:

- x_i – originalna aktivacija i -tog neurona,
- y_i – aktivacija nakon dropout-a,
- r_i – nasumična binarna maska (0 ili 1) generirana iz Bernoulli distribucije,
- p – vjerovatnoća isključivanja neurona.

Dropout je aktivan samo tokom treninga, dok se kod testiranja koriste svi neuroni [8].

2.2.3 Batch Normalization

Tokom treninga, težine neurona se mijenjaju, što dovodi do promjene distribucije ulaza u svaki sloj, te treniranje postaje sporije i teže. Ovaj fenomen se naziva *internal covariate shift*. Batch Normalization rješava ovaj problem normalizirajući (standardizirajući) ulaze u svaki sloj. Ovaj proces se izvodi za mini-batch, malu grupu uzoraka koja se istovremeno obrađuje tokom jedne iteracije treninga. Proces se matematički opisuje sljedećim jednačinama [11]:

$$\mu_B = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.7)$$

$$\sigma_B^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_B)^2 \quad (2.8)$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (2.9)$$

$$y_i = \gamma \hat{x}_i + \beta \quad (2.10)$$

gdje su:

- μ_B – srednja vrijednost mini-batch-a,
- σ_B^2 – varijansa mini-batch-a,
- n – broj uzoraka u mini-batch-u,
- x_i – originalna vrijednost i -tog uzorka,
- $\hat{x}_i$ – normalizirana vrijednost i -tog uzorka,
- ϵ – mala konstanta koja se dodaje radi numeričke stabilnosti (sprječava dijeljenje s nulom),

- y_i – konačna izlazna vrijednost,
- γ, β – parametri koji se uče tokom treniranja (omogućavaju skaliranje i pomjeranje normalizirane vrijednosti).

Bez parametara γ i β , mreža bi imala fiksnu normalizaciju (prosjeak 0 i varijansa 1) za svaki sloj. Kroz backpropagation, mreža uči najbolju vrijednost za γ (skaliranje) i β (pomjeranje), čime se osigurava optimalna distribucija izlaza za svaki sloj [11].

2.2.4 Global Average Pooling

Global Average Pooling (GAP) je tehnika koja se koristi u konvolucijskim neuronskim mrežama za smanjenje broja parametara, pojednostavljenje arhitekture modela, te izdvajanje prostornih informacija iz mapa karakteristika. Za svaku mapu karakteristika računa prosječnu vrijednost, za razliku od Flatten koji sve vrijednosti mape pretvara u jedan vektor. GAP smanjuje broj parametara i overfitting, također poboljšava generalizaciju modela na novim podacima, omogućavajući modelu da prepozna karakteristiku bez obzira gdje se ona pojavljuje na slici [12].

2.2.5 Potpuno povezani slojevi

Nakon konvolucijskih i pooling slojeva, u CNN-u, dolaze potpuno povezani slojevi. Kod njih svaki neuron u jednom sloju je povezan sa svakim neuronom iz prethodnog sloja, pri čemu svaka veza sadrži svoju težinu. Nakon što konvolucijski i pooling slojevi izdvoje karakteristike u mape karakteristika, koje se zatim izravnavaju u 1D vektor pomoću Flatten operacije. Flatten operacija pretvara višedimenzionalnu mapu karakteristika u jednodimenzionalni vektor, zato što potpuno povezani slojevi očekuju vektor na ulazu, a ne višedimenzionalnu strukturu, kao što je matrica. Potpuno povezani slojevi kombinuju sve karakteristike iz vektora i donose konačnu odluku o klasifikaciji [1]. U ovom radu radit će se sa potpuno povezanim posljednjim slojem, koji će imati 1 neuron, s obzirom da se radi o binarnoj klasifikaciji.

2.2.6 3D konvolucijske neuronske mreže

3D konvolucijska neuronska mreža (3D CNN) je arhitektura dubokog učenja razvijena za analizu trodimenzionalnih podataka. Za razliku od 2D CNN koji obrađuje podatke samo po visini i širini, 3D CNN dodaje dimenziju dubine (visina $\times$ širina $\times$ dubina), čime obuhvata prostorne odnose u sve tri dimenzije, što ga čini idealnim za analizu volumetrijskih podataka kao što su CT snimci [1]. U ovom radu koristi se 3D CNN jer su ulazni podaci CT snimci dimenzija $28 \times 28 \times 28$, te je 3D CNN najpogodniji za analizu prostorne strukture plućnih nodula.

2.2.7 ResNet arhitektura

Duboka rezidualna mreža (*ResNet*) jedan je od modela koje su razvili He i saradnici 2016. godine [13]. Duboke neuronske mreže susreću se sa problemom nestajućeg gradijenta. Gradijenti funkcije gubitka, u odnosu na parametre modela, postaju veoma mali tokom *backpropagation* algoritma. ResNet rješava ovaj problem korištenjem rezidualnih veza, koje preskaču jedan ili više slojeva, pri čemu se originalni ulaz x direktno dodaje izlazu slojeva, čime se olakšava propagacija gradijenta kroz duboke slojeve. Matematički se može prikazati slijedećom formulom [13]:

$$y = F(x) + x \quad (2.11)$$

gdje su:

- x – ulazni vektor (shortcut),
- $F(x)$ – naučena rezidualna funkcija (izlaz slojeva),
- y – izlaz rezidualnog bloka.

He i saradnici [13] su pokazali da ResNet model postiže bolje rezultate u klasifikaciji slika od drugih modela [14], zbog čega će se u ovom radu koristiti ResNet arhitektura.

2.2.8 Adam optimizator

Adam je algoritam optimizacije koji ažurira parametre modela koristeći adaptivne stope učenja, zasnovane na prvom i drugom momentu gradijenata. Kombinuje prednosti dvije tehnike: Momentum, koji pamti prethodni smjer ažuriranja težina, i RMSProp, koji prilagođava stopu učenja za svaki parametar posebno [15]. Adam brzo konvergira i dobro radi s velikim skupovima podataka, te podacima s šumom [16].

2.2.9 Loss funkcija

Razliku predikcije modela i stvarne vrijednosti mjeri *loss* funkcija [16].

$$Loss = |Y_{predicted} - Y_{actual}| \quad (2.12)$$

gdje su:

- $Y_{predicted}$ – predikcija modela,
- Y_{actual} – stvarna vrijednost.

Cilj modela je minimizirati *loss* funkciju, s obzirom da ona pokazuje koliko je model pogriješio. U binarnoj klasifikaciji koristi se binarna unakrsna entropija, koja se može matematički prikazati sljedećom formulom [16]:

$$h_p(q) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p(y_i)) + (1 - y_i) \log(1 - p(y_i))] \quad (2.13)$$

gdje su:

- N – ukupan broj uzoraka,
- y_i – stvarna klasa i -tog uzorka (0 ili 1),
- $p(y_i)$ – vjerovatnoća da uzorak pripada klasi 1,
- $1 - p(y_i)$ – vjerovatnoća da uzorak pripada klasi 0.

U većini slučajeva binarna unakrsna entropija se koristi u kombinaciji sa Sigmoid aktivacijskom funkcijom iz razloga što Sigmoid daje izlaz između 0 i 1 (vjerovatnoću), nakon čega binarna unakrsna entropija mjeri razliku između te vjerovatnoće i stvarne klase [16].

U ovom radu koristit će se binarna unakrsna entropija jer je klasifikacija plućnih nodula na benigne i maligne problem s dvije klase.

* * *

U ovom poglavlju opisane su teorijske osnove neuronskih mreža, CNN-a i njegovih komponenti, 3D CNN-a i ResNeta. Opisane metode i tehnike primijenit će se u sljedećem poglavlju u implementaciji, treniranju i evaluaciji 3D CNN i ResNet3D modela.

Poglavlje 3


Implementacija

Implementacija je izvedena u programskom jeziku Python [17], korištenjem TensorFlow/Keras frameworka [18], u okruženju Google Colab [19], cloud platformi koja pruža besplatan pristup GPU akceleraciji. Korišteno je Python notebook okruženje koje je idealno za treniranje DL modela [19]. S obzirom da se radi o cloud platformi, svo računanje odvija se na Googleovim udaljenim serverima, čime se eliminira potreba za snažnim lokalnim hardverom.

3.1 NoduleMNIST3D skup podataka

Za potrebe ovog rada korišten je NoduleMNIST3D skup podataka, jedan od skupova podataka MedMNIST-a. MedMNIST je velika kolekcija standardiziranih biomedicinskih slika slična MNIST-u, uključujući 12 skupova podataka za 2D i 6 skupova podataka za 3D, među kojima je i NoduleMNIST3D.

NoduleMNIST3D se zasniva na LIDC-IDRI, velikom javnom skupu podataka o plućnim nodulima, koji sadrži slike s torakalnih CT snimaka. Skup podataka je dizajniran za klasifikaciju plućnih nodula prema nivou maligniteta. Slike su prethodno obrađene u $28 \times 28 \times 28$ (3D) s odgovarajućim klasifikacijskim oznakama, te je namijenjen za binarnu klasifikaciju. Za potrebe binarne klasifikacije, noduli s nivoom maligniteta 1/2 svrstani su u negativnu klasu (benigni) i 4/5 u pozitivnu klasu (maligni), noduli s nivoom maligniteta 3 su isključeni iz skupa podataka. Skup podataka je podijeljen u omjeru 7:1:2 na skup podataka za treniranje, skup podataka za validaciju i skup podataka za testiranje. Skup podataka za treniranje sadrži 1.158 uzoraka, skup podataka za validaciju 165, a skup podataka za testiranje 310 uzoraka. Skup podataka za treniranje je nebalansiran, s obzirom da ima 863 benignih (75%), a 295 malignih uzoraka (25%). Skup podataka za validaciju sadrži 123 benignih i 42 malignih uzoraka, dok skup podataka za testiranje sadrži 246 benignih i 64 malignih uzoraka. [10].



Slika 3.1: Primjeri plućnih nodula iz NoduleMNIST3D skupa podataka – benigni (gore) i maligni (dole)

Na slici 3.1 prikazani su primjeri presjeka plućnih nodula iz NoduleMNIST3D skupa podataka, pri čemu gornji red prikazuje benigne, a donji maligne nodule.


Podaci su učitani korištenjem medmnist biblioteke, koja pruža direktan pristup NoduleMNIST3D skupu podataka. Nakon učitavanja podaci su imali oblik (1158, 1, 28, 28, 28). S obzirom da MedMNIST vraća podatke u obliku: (broj_uzoraka, 1, 28, 28, 28) bilo je potrebno primijeniti squeeze operaciju kojom je uklonjena dimenzija s pozicije 1, te je channel dimenzija dodana na kraj pomoću newaxis operacije. Rezultat toga su bili podaci oblika (1158, 28, 28, 28, 1), spremni za TensorFlow/Keras koji očekuje podatke oblika: (broj_uzoraka, visina, širina, dubina, kanali). Vrijednosti piksela već su normalizirane (0-1) u skupu podataka, te ih nije bilo potrebno dodatno normalizirati. S obzirom na nebalansiranost skupa podataka, ispitano je ponderiranje klasa, međutim model je pokazao stabilnije treniranje bez ponderiranja.

3.2 Arhitektura modela

U sklopu ovog rada implementirana su dva modela: 3D CNN, kao osnovni model, i ResNet kao napredniji model. Oba modela implementirana su u TensorFlow/Keras frameworku u cilju poređenja njihovih performansi.

3.2.1 3D CNN

Implementirani 3D CNN model sastoji se od dva konvolucijska bloka i klasifikacijskog dijela koji donosi konačnu odluku o klasifikaciji. Na slici 3.2 prikazan je blokovski dijagram arhitekture modela.



Slika 3.2: Blokovski dijagram arhitekture 3D CNN modela

Prvi konvolucijski blok sadrži Conv3D sloj s 16 filtera i kernelom $3 \times 3 \times 3$ koji uči karakteristike iz volumena, nakon čega slijede BatchNormalization, koji normalizuje izlaz konvolucijskog sloja i stabilizuje treniranje, MaxPooling3D($2 \times 2 \times 2$), koji smanjuje dimenzije mape karakteristika za faktor 2, te Dropout(0.25), čime se nasumično isključuje 25% neurona tokom treniranja i sprječava overfitting. Drugi konvolucijski blok uči složenije karakteristike, te se od prvog razlikuje samo u Conv3D sloju koji sada ima 32 filtera: Conv3D(32 filtera, $3 \times 3 \times 3$). Klasifikacijski dio sastoji se od: Flatten, Dense(64, ReLU), Dropout(0.5), Dense(1, Sigmoid), te svaki od njih ima svoju ulogu. Flatten 3D mapu karakteristika iz konvolucijskih blokova

izravnava u 1D vektor [8]. Dense(64, ReLU) je potpuno povezani sloj sa 64 neurona, te je svaki neuron povezan sa svakim elementom vektora. Ovaj sloj uči kombinacije karakteristika iz prethodnih slojeva, te priprema finalnu odluku [8]. Dropout sloj ovdje isključuje veći broj neurona (50%), u poređenju sa konvolucijskim blokovima, iz razloga što Dense slojevi imaju više parametara, stoga i veći rizik od overfittinga [8]. Drugi Dense sloj sadrži samo jedan neuron, s obzirom da se radi o binarnoj klasifikaciji, te Sigmoid aktivacijsku funkciju, koja vraća vrijednost u intervalu od 0 do 1, predstavljajući vjerovatnoću da nodula pripada malignoj klasi. Ukoliko je izlazna vrijednost veća od 0.5, nodula se klasificira kao maligna, u suprotnom kao benigna. Ukupan broj parametara modela iznosi 716.993.

```
def build_simple_3d_cnn():
    model = models.Sequential([
        layers.Conv3D(16, (3,3,3),
                      activation='relu',
                      padding='same',
                      input_shape=(28,28,28,1)),
        layers.BatchNormalization(),
        layers.MaxPooling3D((2,2,2)),
        layers.Dropout(0.25),

        layers.Conv3D(32, (3,3,3),
                      activation='relu',
                      padding='same'),
        layers.BatchNormalization(),
        layers.MaxPooling3D((2,2,2)),
        layers.Dropout(0.25),

        layers.Flatten(),
        layers.Dense(64, activation='relu'),
        layers.Dropout(0.5),
        layers.Dense(1, activation='sigmoid')
    ])
```

Slika 3.3: Implementacija 3D CNN arhitekture u TensorFlow/Keras

```
cnn_model.summary()
```

Model: "sequential"


Layer (type)	Output Shape	Param #
conv3d (Conv3D)	(None, 28, 28, 28, 16)	448
batch_normalization (BatchNormalization)	(None, 28, 28, 28, 16)	64
max_pooling3d (MaxPooling3D)	(None, 14, 14, 14, 16)	0
dropout (Dropout)	(None, 14, 14, 14, 16)	0
conv3d_1 (Conv3D)	(None, 14, 14, 14, 32)	13,856
batch_normalization_1 (BatchNormalization)	(None, 14, 14, 14, 32)	128
max_pooling3d_1 (MaxPooling3D)	(None, 7, 7, 7, 32)	0
dropout_1 (Dropout)	(None, 7, 7, 7, 32)	0
flatten (Flatten)	(None, 10976)	0
dense (Dense)	(None, 64)	702,528
dropout_2 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65

Total params: 2,151,077 (8.21 MB)
 Trainable params: 716,993 (2.74 MB)
 Non-trainable params: 96 (384.00 B)
 Optimizer params: 1,433,988 (5.47 MB)

Slika 3.4: Pregled slojeva i parametara 3D CNN modela

3.2.2 ResNet3D

Implementirani ResNet model sastoji se od dva rezidualna bloka. Na slici 3.5 prikazan je blokovski dijagram arhitekture modela.



Slika 3.5: Blokovski dijagram arhitekture ResNet modela

Prvi rezidualni blok počinje Conv3D slojem s 32 filtera i kernelom $3 \times 3 \times 3$, nakon čega slijede MaxPooling3D($2 \times 2 \times 2$) i Dropout(0.25). Ulaz nakon poolinga sprema se kao shortcut veza. Zatim slijede dva Conv3D sloja, a njihov izlaz se sabire sa shortcut vezom, čime se implementira rezidualna veza opisana u Poglavlju 2, te slijede ReLU aktivacija i Dropout(0.25). Drugi blok se razlikuje od prvog po broju filtera u Conv3D sloju, koji sada ima 64 filtera kako bi mogao učiti složenije karakteristike, te također sadrži MaxPooling3D ($2 \times 2 \times 2$). Nakon dva rezidualna bloka, feature mapa ima oblik: $7 \times 7 \times 7 \times 64$, te bi Flatten sloj dao ogroman broj neurona. Zbog toga za razliku od 3D CNN modela, ResNet koristi GlobalAveragePooling3D umjesto Flatten-a. GlobalAveragePooling3D daje jedan prosjek po svakoj mapi karakteristika, te broj neurona bude jednak broju mapa, što u ovom primjeru iznosi 64. Nakon GlobalAveragePooling3D, slijede Dense(64, ReLU), Dropout(0.5) i Dense(1, Sigmoid), identično klasiifikacijskom dijelu 3D CNN modela. Ukupan broj parametara modela iznosi 228.609, što je značajno manje od 3D CNN modela (716.993). Zbog nestabilnosti treniranja na malom skupu podataka, BatchNormalization je izostavljen iz ResNet arhitekture, što je rezultiralo stabilnijim treniranjem modela.

```
def build_resnet3d_no_bn():
    inputs = layers.Input(shape=(28,28,28,1))

    x = layers.Conv3D(32, (3,3,3),
                      padding='same',
                      activation='relu')(inputs)
    x = layers.MaxPooling3D((2,2,2))(x)
    x = layers.Dropout(0.25)(x)

    shortcut1 = x
    x = layers.Conv3D(32, (3,3,3),
                      padding='same',
                      activation='relu')(x)
    x = layers.Conv3D(32, (3,3,3),
                      padding='same')(x)
    x = layers.Add()([x, shortcut1])
    x = layers.Activation('relu')(x)
    x = layers.Dropout(0.25)(x)
    x = layers.MaxPooling3D((2,2,2))(x)

    shortcut2 = x
    x = layers.Conv3D(64, (3,3,3),
                      padding='same',
                      activation='relu')(x)
    x = layers.Conv3D(64, (3,3,3),
                      padding='same')(x)
    x = layers.Add()([x, shortcut2])
    x = layers.Activation('relu')(x)
    x = layers.Dropout(0.25)(x)

    x = layers.GlobalAveragePooling3D()(x)
    x = layers.Dense(64, activation='relu')(x)
    x = layers.Dropout(0.5)(x)
    outputs = layers.Dense(1, activation='sigmoid')(x)

    model = models.Model(inputs, outputs)
    return model
```

Slika 3.6: Implementacija ResNet arhitekture u TensorFlow/Keras

```
resnet_model = tf.keras.models.load_model('resnet_model.h5')
resnet_model.summary()
```

WARNING:absl:Compiled the loaded model, but the compiled metrics have yet to be built. 'model.compile_metrics' will be empty until you train or evaluate the model.
Model: "functional_12"

Layer (type)	Output Shape	Param #	Connected to
input_layer_12 (InputLayer)	(None, 28, 28, 3)	0	-
conv3d_62 (conv3D)	(None, 28, 28, 28)	896	input_layer_12[...]
max_pooling3d_23 (MaxPooling3D)	(None, 14, 14, 14)	0	conv3d_62[...]
dropout_44 (Dropout)	(None, 14, 14, 14)	0	max_pooling3d_23[...]
conv3d_63 (conv3D)	(None, 14, 14, 14)	27,680	dropout_44[...]
conv3d_64 (conv3D)	(None, 14, 14, 14)	27,680	conv3d_63[...]
add_15 (Add)	(None, 14, 14, 14)	0	conv3d_64[...], conv3d_63[...]
dropout_45 (Dropout)	(None, 14, 14, 14)	0	add_15[...]
max_pooling3d_24 (MaxPooling3D)	(None, 7, 7, 7)	0	dropout_45[...]
conv3d_66 (conv3D)	(None, 7, 7, 7)	55,360	max_pooling3d_24[...]
conv3d_67 (conv3D)	(None, 7, 7, 7)	110,656	conv3d_66[...]
conv3d_65 (conv3D)	(None, 7, 7, 7)	2,112	max_pooling3d_24[...]
add_16 (Add)	(None, 7, 7, 7)	0	conv3d_67[...], conv3d_65[...]
dropout_46 (Dropout)	(None, 7, 7, 7)	0	add_16[...]
global_average_pooling3d_24 (GlobalAveragePooling3D)	(None, 4)	0	dropout_46[...]
dense_24 (Dense)	(None, 4)	4,160	global_average_pooling3d_24[...]
dropout_47 (Dropout)	(None, 4)	0	dense_24[...]
dense_25 (Dense)	(None, 1)	65	dropout_47[...]

Total params: 228,611 (893.82 KB)
Trainable params: 228,611 (893.82 KB)
Non-trainable params: 0 (0.00 B)
Optimizer params: 2 (12.00 B)

Slika 3.7: Pregled slojeva i parametara ResNet modela

3.3 Trening i evaluacija

Oba modela su trenirana istim pristupom, korištenjem Adam optimizatora s početnom stopom učenja 0.0001, Binary Cross-Entropy kao funkcijom gubitka i veličinom batcha od 32 uzorka.

U cilju sprečavanja overfittinga i smanjenja vremena treniranja korišten je Early Stopping, callback koji zaustavlja treniranje ako se model prestane poboljšavati. Prati validacijski gubitak (engl. *val_loss*), ukoliko se *val_loss* ne poboljša određeni broj epoha prestaje treniranje modela. Broj epoha koje model može čekati bez poboljšanja prije nego što se trening zaustavi je *patience*. Kod CNN modela *patience* je 10, dok je kod ResNet modela *patience* 15. Razlika u *patience* vrijednosti rezultat je ukupnog broja epoha treniranja – CNN je treniran maksimalno 50 epoha, dok je ResNet treniran maksimalno 100 epoha. Nakon zaustavljanja, model se vraća na težine iz epohe s najboljim *val_lossom*.

Kako bi model pronašao bolje rješenje koristi se callback koji automatski smanjuje stopu učenja (*lr*), *ReduceLROnPlateau*. Velika stopa učenja ubrzava treniranje ali može preskočiti optimalno rješenje, dok mala stopa učenja omogućava preciznije traženje minimuma. Potrebno je naći balans, pravu vrijednost stope učenja, *ReduceLROnPlateau* pomaže u tome. CNN model imao je nestabilan *val_loss* na početku, korišten je *ReduceLROnPlateau* za stabilizaciju, dok za ResNet to nije bilo potrebno, s obzirom da je konvergirao stabilno s fiksnim *lr*. Korišteni parametri su:

- `monitor='val_loss'` – prati validacijski gubitak,
- `patience=5` – čeka 5 epoha bez poboljšanja,
- `factor=0.5` – prepolaži trenutnu stopu učenja,

- `min_lr=0.00001` – minimalna dozvoljena stopa učenja.

Na slici 3.8 prikazan je kod treniranja 3D CNN modela.

```
cnn_model = build_simple_3d_cnn()

early_stopping = EarlyStopping(
    monitor='val_loss',
    patience=10,
    restore_best_weights=True
)

reduce_lr = ReduceLROnPlateau(
    monitor='val_loss',
    factor=0.5,
    patience=5,
    min_lr=0.00001,
    verbose=1
)

history_cnn = cnn_model.fit(
    X_train, y_train,
    epochs=50,
    batch_size=32,
    validation_data=(X_val, y_val),
    callbacks=[early_stopping, reduce_lr],
    verbose=1
)
```

Slika 3.8: Kod treniranja 3D CNN modela

Na slici 3.9 prikazan je kod treniranja ResNet modela.

```
resnet_model = build_resnet3d_no_bn()

early_stop = EarlyStopping(
    monitor='val_loss',
    patience=15,
    restore_best_weights=True
)

history_resnet = resnet_model.fit(
    X_train, y_train,
    epochs=100,
    batch_size=32,
    validation_data=(X_val, y_val),
    callbacks=[early_stop],
    verbose=1
)
```

Slika 3.9: Kod treniranja ResNet modela

Za procjenu performansi modela korišteno je više metrika evaluacije, s obzirom da sama tačnost (accuracy) može biti varljiva kod nebalansiranih skupova podataka, kao što je odabrani skup podataka. Tačnost (accuracy) računa se kao omjer ispravno klasificiranih uzoraka i ukupnog broja uzoraka [1]:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

Detaljan prikaz predikcija modela daje nam Confusion Matrix. Ona prikazuje 4 ishoda klasifikacije [1]:

- *True Positive* (TP) – ispravno predviđeni maligni,
- *True Negative* (TN) – ispravno predviđeni benigni,
- *False Positive* (FP) – benigni predviđeni kao maligni,
- *False Negative* (FN) – maligni predviđeni kao benigni.

U medicinskoj dijagnostici najveće posljedice može donijeti FN, jer predstavlja propuštene maligne nodule koji mogu ugroziti život pacijenta [1].

Precision mjeri omjer ispravno predviđenih malignih uzoraka od ukupno predviđenih malignih, ukoliko je visok precision model je dobar i sadrži malo lažno pozitivnih predikcija. Međutim, ne uzima u obzir propuštene maligne nodule (FN), zbog čega se koristi zajedno s Recall metrikom. Matematički se može pokazati slijedećom formulom [1]:

$$Precision = \frac{TP}{TP + FP} \quad (3.2)$$

Recall mjeri omjer ispravno detektovanih malignih uzoraka od ukupnog broja stvarnih malignih uzoraka [1]:

$$Recall = \frac{TP}{TP + FN} \quad (3.3)$$


S obzirom da visok Recall ukazuje na mali broj propuštenih malignih nodula [1], ova metrika je najvažnija u ovom medicinskom klasifikacijskom zadatku.

F1 score koristi rezultate Precision i Recall metrika, te predstavlja njihovu harmonijsku sredinu [1]:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (3.4)$$

Visok F1 score predstavlja dobar balans između Precision i Recall, a to je posebno važno kod nebalansiranih skupova podataka, kao što je slučaj u ovom skupu podataka koji sadrži 75% benignih i 25% malignih uzoraka [1].

AUC-ROC je metrika koja mjeri sposobnost modela da razlikuje klase. ROC je graf koji prikazuje odnos između TPR (Recall) i FPR (False Positive Rate), koji predstavlja udio benignih uzoraka pogrešno klasificiranih kao maligni. Svaka tačka na krivulji predstavlja jedan prag klasifikacije. Površina ispod ROC krivulje je AUC, te predstavlja jedan broj koji sažima cijelu krivulju. Vrijednost AUC-a kreće se od 0 do 1, gdje vrijednost bliža 1 ukazuje na bolji model, a 0.5 odgovara slučajnom pogađanju. Visok AUC-ROC rezultat pokazuje da model efikasno razlikuje pozitivne i negativne instance, te je pouzdan u donošenju dijagnostičkih ishoda [1]. AUC-ROC je posebno korisna kod nebalansiranih skupova podataka i kod poređenja modela [1], što je slučaj u ovom radu.



Slika 3.10: Grafovi tačnosti i gubitka tokom treniranja 3D CNN i ResNet modela

Kao što je vidljivo na slici 3.10, 3D CNN model konvergira brzo, počevši od $\approx 38\%$, te brzo raste dostigavši validacijsku tačnost od $\approx 84\%$. Train tačnost počinje od $\approx 74\%$, te dostiže tačnost $\approx 90\%$. Istovremeno, train loss postepeno opada, dok se validacijski loss nakon početnog smanjenja uglavnom stabilizuje. Razlika između trening i validacijskih vrijednosti u kasnijim epohama ukazuje na pojavu blagog overfittinga, jer model nastavlja poboljšavati rezultate na skupu podataka za treniranje, dok se rezultati na skupu podataka za validaciju više ne poboljšavaju u istoj mjeri.

ResNet model pokazuje nešto sporiji početak učenja, ali uprkos tome, na kraju treniranja dostiže sličnu tačnost kao CNN model, $\approx 86\%$. Validacijska tačnost također raste nakon početnih epoha, ali tokom treniranja pokazuje oscilacije i uglavnom se kreće u rasponu od 82% do 85%. Kod gubitka se uočava opadanje i za skup podataka za treniranje i za skup podataka za validaciju. Train loss kontinuirano opada i na kraju dostiže $\approx 0,35$, dok validacijski loss pokazuje veće oscilacije, ali opada prema vrijednosti od $\approx 0,41$. Razlika između train i validacijskog loss-a u kasnijim epohama ukazuje na određeni stepen overfittinga i kod ResNet modela.

Nažalost, i pored primijenjenih tehnika regularizacije, blagi overfitting i dalje je primjetan.

* * *

U ovom poglavlju opisana je implementacija 3D CNN i ResNet modela za klasifikaciju CT slika, te su odabrani parametri treniranja koji su pokazali stabilno konvergiranje oba modela. Rezultati evaluacije implementiranih modela prikazani su u narednom poglavlju.

Poglavlje 4

Rezultati i diskusija

U ovom poglavlju prikazani su rezultati evaluacije dva implementirana modela, 3D CNN i ResNet, na NoduleMNIST3D skupu podataka za treniranje od 310 uzoraka. Za evaluaciju korištene su metrike opisane u poglavlju 3.3: Accuracy, AUC, Precision, Recall, F1 i Confusion Matrix. Poglavlje se osvrće na rezultate oba modela, njihovo međusobno poređenje, poređenje s literaturom te diskusiju o dobivenim rezultatima.

4.1 Rezultati


Nakon treniranja, oba modela su evaluirana na skupu podataka za treniranje za testiranje od 310 uzoraka. Tabela 4.1 prikazuje vrijednosti svih metrika evaluacije za oba implementirana modela.

Tabela 4.1: Poređenje rezultata 3D CNN i ResNet modela

Metrika	3D CNN	ResNet
Accuracy	83.55%	83.23%
AUC	88.31%	86.12%
Precision (Maligni)	58%	62%
Recall (Maligni)	72%	50%
F1 (Maligni)	64%	55%
TP	46	32
TN	213	226
FP	33	20
FN	18	32


U tabeli 4.1 vidimo detaljnu analizu oba modela. Tačnost (accuracy) 3D CNN modela je 83.55%, a ResNet modela 83.23%. Oba modela imaju visoku tačnost, razlika je veoma mala (3D CNN je imao jednu tačnu klasifikaciju više), ali s obzirom da je riječ o nebalansiranom

skupu ostale metrike su važnije u prikazu rezultata modela. AUC metrika kod 3D CNN modela je 88.31%, dok je kod ResNet modela 86.12%, te je razlika nešto izražajna. Viši AUC kod 3D CNN-a ukazuje da on ima bolju sposobnost razlikovanja benignih i malignih slučajeva [10]. Od svih predviđenih malignih, koliko ih je zaista maligno mjeri Precision metrika, a ResNet model je imao bolje rezultate. Dakle ResNet je imao Precision 62%, dok je 3D CNN imao 58%. Najvažnija razlika između modela vidi se u Recall metrici. 3D CNN je pronašao 46 od 64 malignih slučajeva, sa druge strane ResNet je pronašao samo 32 od 64 malignih slučajeva. Za medicinsku klasifikaciju ovo je vrlo značajno, jer je propuštanje stvarno malignog slučaja (FN) često ozbiljniji problem od pogrešnog označavanja benignog slučaja kao malignog (FP) [1]. Gledajući F1 metriku, iako ResNet ima bolji Precision, 3D CNN ima mnogo bolji Recall, te samim tim ostvaruje i bolji F1. True Positive metrika: 3D CNN je ispravno prepoznao 46 malignih slučajeva, dok je ResNet prepoznao samo 32, zbog čega je i nastala razlika u Recall-u. Kod True Negative rezultati su obrnuti, ResNet je pravilno klasifikovao 226 benignih slučajeva, dok je 3D CNN pravilno klasifikovao 213 benignih slučajeva. Benigni slučaj je pogrešno klasifikovan kao maligni (FP) je češća pojava kod 3D CNN, koji je imao 33 ovakve greške, u odnosu na 20, koliko ih je imao ResNet model. Međutim ResNet ima veliku slabost, a to je propuštanje malignih slučajeva. On je klasifikovao 32 maligna slučaja kao benigne, dok je CNN napravio 18 takvih grešaka.




Slika 4.1: Confusion Matrix za 3D CNN i ResNet model

Na slici 4.1 vizuelno su prikazani rezultati klasifikacije, gdje tamnija polja označavaju veći broj uzoraka. Jasno je vidljivo da 3D CNN model ima značajno manji broj propuštenih malignih slučajeva (FN=18) u poređenju s ResNet modelom (FN=32).




Slika 4.2: ROC krivulja za 3D CNN i ResNet model

Na slici 4.2 prikazane su ROC krivulje oba modela. Idealna ROC krivulja teži prema gornjem lijevom uglu, a crna isprekidana linija predstavlja slučajno pogađanje ($AUC=0.5$). Vidljivo je da su oba modela značajno bolja od slučajnog pogađanja. CNN ima vrijednost AUC 0.8831, a ResNet 0.8612. Iako razlika od 0,0219 nije velika, ukazuje na bolju sposobnost 3D CNN modela da razlikuje benigne od malignih slučajeva kroz različite pragove klasifikacije. Uprkos tome što se ROC krive u pojedinim područjima međusobno približavaju, 3D CNN u većem dijelu ROC prostora ostvaruje povoljniji odnos između stope istinito pozitivnih (TPR) i stope lažno pozitivnih (FPR).




Slika 4.3: Maligni noduli koje 3D CNN model ispravno klasificira, a ResNet model propušta (FN)

Na slici 4.3 prikazani su primjeri malignih nodula koje 3D CNN model ispravno klasificira, a ResNet model propušta. Vidimo da CNN model daje vjerojatnoću između 0.55 i 0.57, te klasificira nodule kao maligne, dok ResNet model daje vjerojatnoću između 0.25 i 0.34 i klasificira ih kao benigne. Razlika u vjerojatnoćama ukazuje da CNN model bolje detektuje ove nodule, što potvrđuje viši Recall CNN modela (72% naspram 50%).




Slika 4.4: Maligni noduli koje oba modela ispravno klasificiraju (TP)

Na slici 4.4 prikazani su maligni noduli koje oba modela ispravno klasificiraju. Oba modela daju visoku vjerovatnoću, CNN veću od 0.7, a ResNet veću od 0.6. Ovi noduli imaju jasniju strukturu, što je vidljivo na slikama, te su oba modela uspješno detektovala maligne karakteristike.



Slika 4.5: Maligni noduli koje oba modela propuštaju (FN)

Na slici 4.5 prikazani su maligni noduli koje oba modela propuštaju. Vidimo da oba modela daju nisku vjerovatnoću, manju od 0.5. Noduli vizuelno izgledaju nejasno, također niska rezolucija slika može biti uzrok pogrešne klasifikacije. Ovakvi noduli doprinose ukupnom broju propuštenih malignih slučajeva kod oba modela.



Slika 4.6: Benigni noduli koje CNN pogrešno klasificira kao maligne (FP), a ResNet ispravno (TN)

Na slici 4.6 prikazani su benigni noduli koje CNN model pogrešno klasificira kao maligne, a ResNet model ispravno. CNN model daje vjerovatnoću u rasponu od 0.58 do 0.75 i klasificira nodule kao maligne, dok ResNet model ispravno klasificira iste nodule kao benigne, dajući vjerovatnoću u rasponu od 0.25 do 0.40. Vizualno ovi benigni noduli nalikuju na maligne, te to može biti razlog greške CNN modela. Razlika u vjerovatnoćama ukazuje da ResNet model preciznije klasificira benigne nodule, što objašnjava bolji Precision ResNet modela (62% naspram 58%).

4.2 Poređenje s literaturom

Poređenje s literaturom važno je za validaciju rezultata i pokazuje da li je pristup konkurentan postojećim metodama. Dobiveni rezultati poređeni su s radovima [10] i [6]. Yang i saradnici koristili su isti skup podataka (NoduleMNIST3D), što omogućava direktno poređenje. Song i saradnici radili su klasifikaciju plućnih nodula na LIDC-IDRI skupu podataka – sličan problem ali drugačiji skup podataka, zbog čega poređenje nije direktno, ali pruža koristan kontekst.

Tabela 4.2: Poređenje rezultata s literaturom

Rad	Model	Skup podataka	ACC	AUC	Recall
Song et al. (2017)	CNN	LIDC-IDRI	84.15%	91.6%	83.96%
Yang et al. (2023)	ResNet-18 (3D)	NoduleMNIST3D	84.4%	86.3%	/
Ovaj rad	3D CNN	NoduleMNIST3D	83.55%	88.31%	72%
Ovaj rad	ResNet	NoduleMNIST3D	83.23%	86.12%	50%

Poređenje sa Song et al. (2017): Razlika u accuracy metrici je relativno mala. Implementirani CNN model ima 83.55%, dok Song ima 84.15% [6], te je model veoma blizu rezultatu Song et al. Razlika u AUC je nešto veća 3.29 procentnih poena, to pokazuje da njihov CNN pokazuje bolju sposobnost razlikovanja benignih od malignih slučajeva, ali potrebno je uzeti u obzir da modeli rade na dva različita skupa podataka. Najveća razlika primjećuje se u Recall metrici, koja iznosi 11.96 procentnih poena. Song koristi 5024 uzoraka [6], a korišteni skup podataka 1158 uzoraka, te je razlika u veličini skupa podataka mogla utjecati na razliku u rezultatima. Veći skup podataka generalno doprinosi boljim rezultatima modela.

Direktnije poređenje omogućava rad Yang i saradnika [10], koji koristi isti skup podataka, NoduleMNIST3D. Implementirani 3D CNN model postigao je AUC od 88.31%, što je više od ResNet-18 (3D) modela Yang i saradnika koji postiže AUC od 86.3% [10], što predstavlja poboljšanje od 2.01 procentnih poena. Međutim, u accuracy metrici Yang i saradnici postižu 84.4% [10], dok implementirani CNN postiže 83.55%, što je razlika od 0.85 procentnih poena. Implementirani ResNet model postiže AUC od 86.12%, što je gotovo identično ResNet-18 (3D) modelu Yang i saradnika (86.3%) [10]. U accuracy metrici, implementirani ResNet postiže 83.23%, dok Yang i saradnici postižu 84.4% [10], što je razlika od 1.17 procentnih poena. Generalno, dobiveni rezultati su kompetitivni s objavljenim benchmark rezultatima, posebno po AUC metrici, gdje implementirani CNN model nadmašuje ResNet-18 (3D) iz Yang i saradnika. Također treba imati u vidu da je implementirani ResNet jednostavnija verzija, dok je model Yanga i saradnika, ResNet-18, standardni ImageNet model što pojašnjava nešto lošiju accuracy implementiranog ResNet modela.

4.3 Diskusija

Iako oba implementirana modela postižu sličnu ukupnu tačnost ($\approx 83\%$), sama tačnost nije dovoljna metrika za procjenu modela, posebno kod nebalansiranih skupova podataka [1]. Analiza ostalih metrika ukazuje na značajne razlike između 3D CNN i ResNet modela. Razlika u Recall

metrici je značajna – CNN model postiže 72%, a ResNet samo 50%. Razlika u AUC iznosi 2.19 procentnih poena (CNN 88.31% naspram ResNet 86.12%). Navedeni rezultati sugeriraju da je CNN ukupno povoljniji model.

Analiza Confusion Matrix otkriva različite obrasce klasifikacijskih grešaka. CNN model ostvaruje veći broj lažno pozitivnih (FP) i manje lažno negativnih (FN), dok je kod ResNet modela obrnuto. Veći broj lažno pozitivnih klasifikacija kod CNN modela doprinosi njegovom nižem Precision rezultatu, dok veći broj lažno negativnih klasifikacija kod ResNet modela doprinosi njegovom nižem Recall rezultatu. Modeli imaju različit kompromis između FP i FN, pa se izbor modela ne može zasnivati samo na Accuracy.

Kod medicinske klasifikacije važno je razmotriti lažno negativne rezultate (FN), u ovom radu to je situaciju u kojoj je stvarno maligni slučaj klasifikovan kao benigni. Važnost se ogleda u tome da ukoliko model nije prepoznao malignu promjenu, odnosno potencijalno važan slučaj ostaje neidentifikovan. ResNet model ostvaruje veći broj propuštenih malignih slučajeva, čak 14 više propuštenih slučajeva od CNN modela. Recall pokazuje udio stvarno malignih slučajeva koje je model uspješno prepoznao, pri čemu veći broj lažno negativnih rezultata dovodi do niže vrijednosti Recall metrike. S druge strane, lažno pozitivni rezultati (FP) predstavljaju situaciju u kojoj je benigni slučaj klasifikovan kao maligni. Cilj je da model, pored FN, ima što manji broj i FP, a metrika Precision nam omogućava da to pratimo. CNN je skloniji označiti više slučajeva kao maligne, zbog čega ima više lažnih alarma (FP), ali istovremeno, time propušta manje stvarno malignih slučajeva. ResNet je „konzervativniji” u označavanju slučajeva kao malignih: ima manje FP, ali zbog toga propušta više malignih slučajeva. S obzirom da je cilj klasifikacija malignih i benignih plućnih nodula, Recall je od posebnog značaja, jer je propuštanje stvarno malignog slučaja potencijalno ozbiljnija greška od dodatnog lažno pozitivnog rezultata. CNN imajući Recall=72% pokazuje povoljnije ponašanje kada je prioritet smanjenje broja propuštenih malignih slučajeva, u kontekstu ovog problema, u odnosu na ResNet sa vrijednošću Recall metrike 50%. CNN ima bolji Recall i manje FN, ali ne znači automatski da je klinički bolji model, jer se ovdje radi o manjem skupu podataka (310 uzoraka) i testiranju samo na NoduleMNIST3D.

AUC metrika procjenjuje sposobnost modela da razlikuje klase kroz različite pragove klasifikacije, te je neovisna o odabranom pragu (*threshold*). CNN postiže AUC 88.31%, a ResNet 86.12%, te je razlika od 2.19 pp konzistentna s boljim Recall i F1 CNN-a. Rezultati sugeriraju bolju sposobnost razdvajanja klasa kod CNN-a, ali ne može se tvrditi statistički značajna razlika bez provođenja dodatnih statističkih testova. Što je vidljivo i na slici 4.2, gdje CNN krivulja u većem dijelu ROC prostora ostvaruje povoljniji odnos između TPR i FPR.

Poređenje s Yang i saradnicima posebno je relevantno jer koriste isti skup podataka, te je moguće bilo direktno poređenje. CNN postiže AUC od 88.31%, što je više od 86.3% koje ostvaruje ResNet-18(3D) [10]. Međutim, u tačnosti CNN postiže 83.55%, dok Yang i saradnici postižu 84.4% [10]. Ovo je moguće jer AUC procjenjuje sposobnost modela kroz sve moguće pragove klasifikacije, dok accuracy ovisi o konkretnom odabranom pragu (0.5). Jedno od mogućih objašnjenja nešto niže tačnosti je razlika u arhitekturi modela – implementirani ResNet je jednostavnija verzija od ResNet-18 koji su koristili Yang i saradnici [10]. Rezultati sugeriraju da implementirani CNN model ostvaruje kompetitivne rezultate u poređenju s benchmark metodama na istom skupu podataka.

Poređenje sa Song i saradnicima nije se moglo direktno sprovesti, jer se radi o različitim skupovima podataka. Songov skup podataka sadrži veći broj uzoraka [6], što može pozitivno uticati na učenje modela. Uz to, prisutna je različita distribucija klasa, kao i različiti eksperimentalni protokol. Zbog navedenih razloga rezultati Song i saradnika korišteni su kao referentni kontekst, a ne osnova za direktno poređenje performansi [6].

Provedeno istraživanje ima nekoliko ograničenja koja treba uzeti u obzir pri interpretaciji rezultata. Radi se o relativno malom skupu podataka s 1158 uzoraka za treniranje, što može ograničiti sposobnost modela da nauči kompleksne obrasce [7]. Također skup podataka je ne-balansiran (75%/25%), što otežava treniranje, te zahtijeva dodatnu pažnju pri odabiru metrika, ali i interpretaciji rezultata, posebno metrika kao što su Precision i Recall. Niska rezolucija slika (28×28×28) može ograničiti sposobnost modela da detektuje fine karakteristike nodula, te uticati na rezultate klasifikacije. Evaluacija modela je rađena na jednom skupu podataka za testiranje, te se rezultati mogu razlikovati pri drugačijoj podjeli podataka ili drugom random seed-u treniranja. S obzirom da je svaki model treniran samo jednom, nije bilo moguće provesti statističku analizu značajnosti razlika između modela. Modeli nisu testirani na eksternom skupu podataka, te se sposobnost generalizacije ne može tačno utvrditi.

Na osnovu provedene analize, uzimajući u obzir sve metrike evaluacije, 3D CNN model se čini povoljnijim izborom za problem klasifikacije CT slika. CNN model ima viši AUC (88.31%) od ResNet modela (86.12%), što ukazuje na bolju sposobnost razlikovanja benignih od malignih slučajeva. Rezultati ukazuju da CNN model ima manje lažno negativnih rezultata (FN=18), od ResNet modela (FN=32) što je posebno važno u kontekstu medicinskog skrininga gdje je prioritet detekcija malignih slučajeva. Međutim, s obzirom na ograničenja istraživanja, ovi rezultati trebaju biti potvrđeni na većim skupovima podataka prije donošenja konačnih zaključaka. Važno je napomenuti da implementirani modeli nisu namijenjeni za direktnu kliničku primjenu, već predstavljaju istraživanje u oblasti automatizirane analize medicinskih slika.

* * *

U ovom poglavlju prikazani su rezultati evaluacije oba modela, njihovo međusobno poređenje, poređenje s literaturom te diskusija rezultata. 3D CNN model pokazao je bolje rezultate, posebno po AUC i Recall metrici. Zaključna razmatranja i smjernice za budući rad dati su u Zaključku.

Zaključak

Ostvareni ciljevi rada/disertacije

U ovom radu implementirana su i evaluirana dva modela dubokog učenja: 3D CNN i ResNet model. Korišten je NoduleMNIST3D skup podataka, te se radilo o problemu binarne klasifikacije plućnih nodula na benigne i maligne. 3D CNN model postigao je tačnost od 83.55% i AUC od 88.31%, dok je ResNet model postigao tačnost od 83.23% i AUC od 86.12%. Poređenjem s literaturom, implementirani CNN model postiže viši AUC od ResNet-18 (3D) Yang i saradnika [10], ostali rezultati poređenja pokazali su da je implementirani model u rangu postojećih metoda iz literature [10] [6]. Na osnovu analize svih metrika, 3D CNN model se pokazao povoljnijim izborom, posebno gledajući Recall metriku (72% naspram 50%), koja je ključna u klasifikaciji medicinskih slika.

3D CNN model stoga pokazuje prednost kada je prioritet ne propustiti maligne nodule, što mjeri Recall metrika. Međutim, ukoliko je prioritet smanjenje broja pogrešno označenih benignih nodula kao malignih (lažno pozitivnih predikcija), ResNet model daje bolje rezultate, imajući bolji rezultat Precision metrike (62% naspram 58%). Izbor modela ovisi o specifičnom cilju klasifikacije i prihvatljivom omjeru između FP i FN grešaka. U području medicine, gdje je prioritet detekcija malignih slučajeva, 3D CNN model se čini povoljnijim izborom.

Dobiveni rezultati potvrđuju upotrebu metoda dubokog učenja za klasifikaciju plućnih nodula na NoduleMNIST3D skupu podataka, te proširuju postojeća istraživanja usporedbom 3D CNN i ResNet arhitektura.

Smjernice za budući rad

Rezultati pokazuju da jednostavniji CNN modeli mogu postići kompetitivne rezultate na NoduleMNIST3D, što može biti korisno istraživačima koji razvijaju metode za automatiziranu analizu CT snimaka.

U budućim istraživanjima moglo bi se razmotriti nekoliko poboljšanja. Jedno od mogućih poboljšanja je korištenje augmentacije podataka (*data augmentation*), koja od postojećeg CT uzorka pravi nove varijante podataka koristeći različite transformacije na originalnom skupu podataka. S obzirom da je korišteni skup podataka relativno mali, augmentacijom model tokom treninga može vidjeti veću raznovrsnost ulaznih podataka, te potencijalno smanjiti overfitting. Međutim, bitno je spomenuti da se kod medicinskih slika ne treba nasumično koristiti svaka transformacija jer se radi o osjetljivim i specifičnim medicinskim podacima gdje određene transformacije mogu narušiti klinički relevantne karakteristike nodula. Također, moglo bi se razmotriti korištenje većeg skupa podataka, koji modelu može pomoći da nauči robustnije karakteristike, smanji overfitting i poboljša generalizaciju. Uz to, testiranje na vanjskom skupu podataka bi bilo korisno, s obzirom da je implementirani model treniran samo na NoduleMNIST3D skupu podataka, te se ne može utvrditi sposobnost generalizacije na različitim skupovima podataka. Primjena cross-validacije omogućila bi procjenu performansi na više podjela. Cross-validacija dijeli skup podataka na više dijelova, u kojoj je uvijek jedan dio skupa

validacijski, te se postupak ponavlja sve dok svaki dio ne bude jednom validacijski. Time se smanjuje ovisnost rezultata od toga koji uzorci su u skupu podataka za treniranje, validaciju i testiranje. Optimizacijom klasifikacijskog praga moglo bi se omogućiti prilagođavanje odnosa između Recall-a i Precision-a specifičnim zahtjevima problema. Snižavanjem praga u pravilu može povećati Recall, ali i smanjiti Precision, dok povišavanjem praga raste Precision, ali pada Recall. Sa medicinskog aspekta, gdje je prioritet smanjenje propuštenih malignih slučajeva, niži prag klasifikacije mogao bi dati povoljnije rezultate. S obzirom da je svaki model treniran samo jednom, rezultati mogu biti pod utjecajem slučajne inicijalizacije težina, te u narednom treniranju rezultati mogu varirati. Višestruko treniranje omogućava pouzdaniju procjenu stvarnih performansi modela, jer neuronske mreže ovise o slučajnim faktorima poput random seed-a i redoslijeda podataka, te uz treniranje više puta mogu se dobiti stabilniji i reprezentativniji rezultati. Također, moglo bi se razmotriti korištenje transfer learninga, gdje bi se pretrained model podesio za klasifikaciju plućnih nodula. Ovo je posebno korisno kod malih skupova podataka.

Očekuje se da primjena navedenih tehnika, uz dalje razvijanje i usavršavanje, može dovesti do poboljšanja rezultata klasifikacije, boljih performansi modela na ovom i sličnim skupovima medicinskih podataka, te doprinijeti razvoju pouzdanijih metoda za automatiziranu analizu medicinskih slika.

Literatura

- [1] Ahmad, I. S., Dai, J., Xie, Y., Liang, X., “Deep Learning Models for CT Image Classification: A Comprehensive Literature Review”, Quantitative Imaging in Medicine and Surgery, Vol. 15, No. 1, 2025, str. 962-1011.
- [2] Biber, D., “Digitalne radiološke metode”, Završni rad, Sveučilište u Splitu, Fakultet zdravstvenih znanosti, Split, Hrvatska, July 2014, dostupno na: <https://urn.nsk.hr/urn:nbn:hr:176:385877>
- [3] Sarvamangala, D. R., Kulkarni, R. V., “Convolutional Neural Networks in Medical Image Understanding: A Survey”, Evolutionary Intelligence, Vol. 15, No. 1, January 2022, str. 1-22.
- [4] Pandian, R., Vedanarayanan, V., Kumar, D. N. S. R., Rajakumar, R., “Detection and Classification of Lung Cancer Using CNN and GoogleNet”, Measurement: Sensors, Vol. 24, 2022, str. 100588.
- [5] Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., Jemal, A., “Global Cancer Statistics 2022: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries”, CA: A Cancer Journal for Clinicians, Vol. 74, No. 3, 2024, str. 229-263.
- [6] Song, Q. Z., Zhao, L., Luo, X. K., Dou, X. C., “Using Deep Learning for Classification of Lung Nodules on Computed Tomography Images”, Journal of Healthcare Engineering, Vol. 2017, August 2017, str. 8314740.
- [7] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., Sánchez, C. I., “A Survey on Deep Learning in Medical Image Analysis”, Medical Image Analysis, Vol. 42, December 2017, str. 60-88.
- [8] Chollet, F., Deep Learning with Python, 1st ed. Shelter Island, NY: Manning Publications, 2017.
- [9] Thanoon, M. A., Zulkifley, M. A., Zainuri, M. A. A. M., Abdani, S. R., “A Review of Deep Learning Techniques for Lung Cancer Screening and Diagnosis Based on CT Images”, Diagnostics, Vol. 13, No. 16, August 2023, str. 2617.
- [10] Yang, J., Shi, R., Wei, D., Liu, Z., Zhao, L., Ke, B., Pfister, H., Ni, B., “MedMNIST v2 – A Large-Scale Lightweight Benchmark for 2D and 3D Biomedical Image Classification”, Scientific Data, Vol. 10, No. 1, 2023, str. 41.
- [11] Ioffe, S., Szegedy, C., “Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”, arXiv preprint arXiv:1502.03167, 2015.

- [12] Lin, M., Chen, Q., Yan, S., “Network In Network”, arXiv:1312.4400, 2014.
- [13] He, K., Zhang, X., Ren, S., Sun, J., “Deep Residual Learning for Image Recognition”, in CVPR, 2016.
- [14] Sarwinda, D., Paradisa, R. H., Bustamam, A., Anggia, P., “Deep Learning in Image Classification using Residual Network (ResNet) Variants for Detection of Colorectal Cancer”, Procedia Computer Science, Vol. 179, 2021, str. 423-431.
- [15] Kingma, D. P., Ba, J., “Adam: A Method for Stochastic Optimization”, arXiv preprint arXiv:1412.6980, 2015.
- [16] Raptis, C., Karavasilis, E., Anastasopoulos, G., Adamopoulos, A., “Comparative Analysis of Conventional CNN v’s ImageNet Pretrained ResNet in Medical Image Classification”, Information, Vol. 15, No. 12, December 2024, str. 806.
- [17] Python Software Foundation, “Python Programming Language”, dostupno na: <https://www.python.org> 2023.
- [18] Martín Abadi et al., “TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems”, dostupno na: <https://www.tensorflow.org> 2015.
- [19] Google Research, “Google Colaboratory”, dostupno na: <https://colab.research.google.com> 2017.